

Atividade 1 - Mineração de Dados

Gabriel M. Brum, Pedro H. M. Gatti

Programa da Pós-Graduação em Ciência da Computação (PPGCC) - UNESP

5 de outubro de 2026

Resumo

resumo

1 Introdução

Nesta atividade foi solicitado escolhermos um conjunto de dados que contenha ao menos 4 classes, então aplicar o pré-processamento que julgássemos adequado. Após isso, deveríamos testar os seguintes algoritmos: árvore, *bagging*, *boosting* e *random forest*. Ao final, avaliar quais deles gerou o melhor modelo usando tanto alguma técnica de validação, escolhendo uma métrica de desempenho. Considerando o de melhor resultado, faça a *setagem* de hiperparâmetros no mesmo para ver se o desempenho melhora. Adicionalmente, deveríamos transformar o problema multiclasse em problemas binários usando OVA e OVO. Escolher uma métrica de desempenho e analisar qual das abordagens se saiu melhor para alguma técnica de avaliação utilizando o algoritmo de árvore.

2 Dataset

O conjunto de dados *Car Evaluation* é um *benchmark* da área de aprendizado de máquina, disponibilizado no repositório UCI por Bohanec e Zupan em 1997 [2]. Sua origem remonta aos trabalhos de Bohanec e Rajkovič (1988, 1990) no contexto de sistemas especialistas de apoio à decisão multicritério (ferramenta DEX) [1]. Originalmente, o domínio foi modelado através de uma estrutura hierárquica na qual seis atributos primários determinavam conceitos intermediários de custo e viabilidade técnica antes de inferir a aceitabilidade final do veículo. Na versão publicada, os conceitos intermediários foram suprimidos, restando uma relação direta entre os seis atributos descritivos e a classe-alvo distribuída em 1728 instâncias (cobrindo a totalidade do espaço vetorial discreto do problema).

O conjunto tem um total de 1728 instâncias, 6 atributos e 4 classes (*unacc* = *unacceptable*, *acc* = *acceptable*, *good* e *vgood* = *very good*) que indicam a condição de compra de veículos. A distribuição de classes está apresentada na Tabela 1, já os atributos estão descritos na Tabela 2.

Tabela 1: Distribuição das classes no conjunto de dados Car Evaluation.

Classe	Quantidade de instâncias	% do total de amostras
<i>unacc</i>	1210	70,023%
<i>acc</i>	384	22,222%
<i>good</i>	69	3,993%
<i>vgood</i>	65	3,762%
Total	1728	100,000%

Tabela 2: Descrição dos atributos e variável-alvo do conjunto de dados Car Evaluation.

Atributo	Valores	Ordem Natural
buying	<i>low, med, high, v-high</i>	low < med < high < v-high
maint	<i>low, med, high, v-high</i>	low < med < high < v-high
doors	<i>2, 3, 4, 5more</i>	2 < 3 < 4 < 5more
persons	<i>2, 4, more</i>	2 < 4 < more
lug_boot	<i>small, med, big</i>	small < med < big
safety	<i>low, med, high</i>	low < med < high
Classe (class)	<i>unacc, acc, good, vgood</i>	unacc < acc < good < vgood

3 Pré-Processamento

Por conta de se tratar de um conjunto de dados categórico, e que possuía ordem entre as classes, optamos por utilizar a técnica de *Ordinal Encoding* para transformar os atributos em valores numéricos. A Tabela 3 apresenta a codificação utilizada para cada atributo.

Tabela 3: Mapeamento de codificação ordinal aplicado aos atributos e à classe-alvo.

Atributo	Categoria Original	Valor Codificado
buying	<i>low, med, high, vhigh</i>	1, 2, 3, 4
maint	<i>low, med, high, vhigh</i>	1, 2, 3, 4
doors	<i>2, 3, 4, 5more</i>	2, 3, 4, 5
persons	<i>2, 4, more</i>	2, 4, 5
lug_boot	<i>small, med, big</i>	1, 2, 3
safety	<i>low, med, high</i>	1, 2, 3
Classe (class)	<i>unacc, acc, good, vgood</i>	0, 1, 2, 3

Referências

- [1] Marko Bohanec and Vladislav Rajkovič. Knowledge acquisition and explanation for multi-attribute decision making. In *Proceedings of the 8th International Workshop on Expert Systems and their Applications*, pages 59–78, Avignon, France, 1988.
- [2] Blaž Zupan, Marko Bohanec, Ivan Bratko, and Janez Demšar. Machine learning by function decomposition. In *Proceedings of the 14th International Conference on Machine Learning (ICML-97)*, pages 421–429, Nashville, TN, 1997.