

Atividade 1 - Mineração de Dados

Gabriel M. Brum, Pedro H. M. Gatti

Programa da Pós-Graduação em Ciência da Computação (PPGCC) - UNESP

5 de outubro de 2026

Resumo

resumo

1 Introdução

Nesta atividade foi solicitado escolhermos um conjunto de dados que contenha ao menos 4 classes, então aplicar o pré-processamento que julgássemos adequado. Após isso, deveríamos testar os seguintes algoritmos: árvore, *bagging*, *boosting* e *random forest*. Ao final, avaliar quais deles gerou o melhor modelo usando tanto alguma técnica de validação, escolhendo uma métrica de desempenho. Considerando o de melhor resultado, faça a *setagem* de hiperparâmetros no mesmo para ver se o desempenho melhora. Adicionalmente, deveríamos transformar o problema multiclasse em problemas binários usando OVA e OVO. Escolher uma métrica de desempenho e analisar qual das abordagens se saiu melhor para alguma técnica de avaliação utilizando o algoritmo de árvore.

2 Dataset

O conjunto de dados *Car Evaluation* é um *benchmark* da área de aprendizado de máquina, disponibilizado no repositório UCI por Bohanec e Zupan em 1997 [?]. Sua origem remonta aos trabalhos de Bohanec e Rajkovič (1988, 1990) no contexto de sistemas especialistas de apoio à decisão multicritério (ferramenta DEX) [?]. Originalmente, o domínio foi modelado através de uma estrutura hierárquica na qual seis atributos primários determinavam conceitos intermediários de custo e viabilidade técnica antes de inferir a aceitabilidade final do veículo. Na versão publicada, os conceitos intermediários foram suprimidos, restando uma relação direta entre os seis atributos descritivos e a classe-alvo distribuída em 1728 instâncias (cobrindo a totalidade do espaço vetorial discreto do problema).

O conjunto tem um total de 1728 instâncias, 6 atributos e 4 classes (*unacc* = *unacceptable*, *acc* = *acceptable*, *good* e *vgood* = *very good*) que indicam a condição de compra de veículos. A distribuição de classes está apresentada na Tabela 1, já os atributos estão descritos na Tabela 2.

Tabela 1: Distribuição das classes no conjunto de dados Car Evaluation.

Classe	Quantidade de instâncias	% do total de amostras
<i>unacc</i>	1210	70,023%
<i>acc</i>	384	22,222%
<i>good</i>	69	3,993%
<i>vgood</i>	65	3,762%
Total	1728	100,000%

Tabela 2: Descrição dos atributos e variável-alvo do conjunto de dados Car Evaluation.

Atributo	Valores	Ordem Natural
buying	<i>low, med, high, v-high</i>	low < med < high < v-high
maint	<i>low, med, high, v-high</i>	low < med < high < v-high
doors	<i>2, 3, 4, 5more</i>	2 < 3 < 4 < 5more
persons	<i>2, 4, more</i>	2 < 4 < more
lug_boot	<i>small, med, big</i>	small < med < big
safety	<i>low, med, high</i>	low < med < high
Classe (class)	<i>unacc, acc, good, vgood</i>	unacc < acc < good < vgood

3 Pré-Processamento

Por conta de se tratar de um conjunto de dados categórico, e que possuía ordem entre as classes, optamos por utilizar a técnica de *Ordinal Encoding* para transformar os atributos em valores numéricos. A Tabela 3 apresenta a codificação utilizada para cada atributo.

Tabela 3: Mapeamento de codificação ordinal aplicado aos atributos e à classe-alvo.

Atributo	Categoria Original	Valor Codificado
buying	<i>low, med, high, vhigh</i>	1, 2, 3, 4
maint	<i>low, med, high, vhigh</i>	1, 2, 3, 4
doors	<i>2, 3, 4, 5more</i>	2, 3, 4, 5
persons	<i>2, 4, more</i>	2, 4, 5
lug_boot	<i>small, med, big</i>	1, 2, 3
safety	<i>low, med, high</i>	1, 2, 3
Classe (class)	<i>unacc, acc, good, vgood</i>	0, 1, 2, 3

4 Metodologia

O procedimento experimental foi estruturado em duas etapas principais, orientadas pelo uso de validação estratificada e pela métrica *Macro F1-Score* ($F1_{\text{macro}}$), fundamental para lidar com o desbalanceamento das quatro classes do problema.

4.1 Parte I: Comparação de Modelos e Otimização de Hiperparâmetros

Nesta etapa, comparou-se o desempenho preditivo de quatro algoritmos de aprendizado de máquina supervisionado:

- **Árvore de Decisão (*Decision Tree*):** Classificador base baseado em divisões recursivas de atributos;
- **Bagging (*Bootstrap Aggregating*):** Comitê que combina estimadores independentes treinados com amostragem com reposição;
- **AdaBoost (*Adaptive Boosting*):** Método de agregação sequencial que ajusta pesos iterativamente para instâncias classificadas incorretamente;
- **Random Forest:** Floresta aleatória que combina amostragem *bootstrap* com seleção aleatória de subconjuntos de atributos em cada nó.

O protocolo de validação adotado para a comparação inicial dos quatro modelos foi a validação cruzada estratificada em 5 *folds* (*Stratified 5-Fold Cross-Validation*) com embaralhamento dos dados (*shuffle*), utilizando o $F1_{\text{macro}}$ como critério decisor.

O classificador que alcançou o maior valor médio de $F1_{\text{macro}}$ foi selecionado para a fase de ajuste fino de hiperparâmetros (*hyperparameter tuning*). O ajuste foi conduzido através de *GridSearchCV* com validação cruzada interna estratificada de 5 *folds* e métrica de pontuação `scoring='f1_macro'`. Por fim, avaliou-se o ganho de desempenho obtido confrontando os resultados do modelo antes e após a otimização no conjunto de teste independente (Holdout 70/30 estratificado).

4.2 Parte II: Decomposição Multiclasse em Problemas Binários

Nesta etapa, investigou-se a estratégia de binarização do problema multiclasse utilizando exclusivamente a Árvore de Decisão (`DecisionTreeClassifier(random_state=42)`) como algoritmo base:

- **One-vs-All (OVA / One-vs-Rest):** Implementado por meio da classe `OneVsRestClassifier`, treina um classificador binário para cada classe contra o agrupamento das demais, totalizando 4 modelos;
- **One-vs-One (OVO):** Implementado por meio da classe `OneVsOneClassifier`, treina um classificador binário dedicado para cada par possível de classes, totalizando $\frac{4 \times 3}{2} = 6$ modelos, com resolução final por votação majoritária.

Ambas as abordagens foram avaliadas sob dois esquemas de validação complementares:

1. **Holdout Estratificado (70/30):** Particionamento dos dados em 70% para treino e 30% para teste (`random_state=42`), preservando a proporção de cada classe. A partir das predições no conjunto de teste, computaram-se a acurácia, o $F1_{\text{macro}}$ e as matrizes de confusão de cada método.
2. **Validação Cruzada Estratificada ($k = 5$):** Avaliação via `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`, mensurando a média e o desvio padrão da acurácia e do $F1_{\text{macro}}$ ao longo das 5 dobras para determinar a abordagem de melhor desempenho.